

Xây Dựng Dữ Liệu Và Mô Hình Phân Loại Đánh Giá Sự Tích Cực/Tiêu Cực Của Các Tin Báo Trên Các Trang Mạng

1. Lê Đức Thành – 23521441
2. Huỳnh Nhật Thanh – 23521440
3. Bùi Thị Thanh Trang – 23521625
4. Đinh Trần Duy Trường – 23521688
5. ThS. Huỳnh Văn Tín

ĐỘNG LỰC THỰC HIỆN

Động lực thực hiện

- Tin tức tăng quá nhanh → đọc không kịp: mỗi ngày hàng loạt bài mới, khó nắm “bức tranh cảm xúc” nếu chỉ đọc thủ công.
- Điều cần là xu hướng, không phải từng bài: cần biết theo chủ đề/nguồn/thời gian đang nghiêng tích cực – tiêu cực – trung tính để ra quyết định nhanh.
- Tin tiêu cực lan nhanh và gây hệ quả: nếu không phát hiện sớm, dễ bỏ lỡ cảnh báo rủi ro (khủng hoảng truyền thông, suy giảm niềm tin, hoang mang xã hội).


Động lực thực hiện

- Đánh giá thủ công thiếu ổn định: tốn thời gian, lệ thuộc người đọc, khó mở rộng khi dữ liệu lớn.
- Giải pháp hợp lý: xây dataset chuẩn + mô hình phân loại để tự động hóa, theo dõi liên tục, cập nhật theo thời gian thực.

ĐỊNH NGHĨA BÀI TOÁN

Định nghĩa bài toán

- **Mục tiêu:** xây dựng dữ liệu gán nhãn và mô hình phân loại sắc thái tin báo tiếng Việt.
- **Bài toán:** phân loại văn bản tin tức (sentiment classification) ở mức bài báo.



Định nghĩa bài toán

- **Input:** nội dung bài báo (tiêu đề + nội dung ngắn).
- **Output (3 nhãn):**
 - + Positive
 - + Negative
 - + Neutral
- **Kết quả kỳ vọng:** gán nhãn tự động cho tin mới + tổng hợp xu hướng sắc thái theo chủ đề/nguồn/thời gian.

TRÍCH XUẤT DỮ LIỆU

Trích xuất dữ liệu

- Nguồn dữ liệu: vietnamnet.vn
- Phạm vi chủ đề:
 - + Chính trị
 - + Quân sự
 - + Showbiz
 - + Đời sống
 - + Bất động sản
 - + Thị trường
 - + ...

Quy trình trích xuất

- Phương pháp: Crawl dữ liệu tự động.
- Cấu trúc mẫu (Sample Structure): Mỗi mẫu dữ liệu được cấu trúc gồm: [Tiêu đề bài báo] + [Câu đầu tiên của bài báo].
- Lý do chọn cấu trúc này: Đây thường là phần tóm tắt nội dung chính (Sapo), chứa đựng cảm xúc chủ đạo hoặc thông điệp cốt lõi của bài viết, giúp giảm nhiều so với việc lấy toàn bộ bài báo dài.

XÂY DỰNG GUILDLINE

Xây dựng Guidline

- **Định nghĩa nhãn Positive:** Bài báo thể hiện sắc thái lạc quan, vui mừng, tự hào hoặc khích lệ, tập trung vào thành công, cải thiện, tiến bộ, cơ hội, hoặc kết quả tốt. Giọng văn thể hiện niềm tin, sự phấn khởi, cảm xúc tích cực, hoặc hướng tới tương lai tươi sáng.

Xây dựng Guildline

— Một số nhóm cụ thể nhận Positive:

- + Thành tựu / Kết quả vượt trội
- + Nhóm Phát triển – Tăng trưởng – Mở rộng
- + Nhóm Tinh thần tích cực – Truyền cảm hứng – Vượt khó
- + Nhóm Nhân văn – Tình cảm ấm áp
- + Nhóm Thể thao với kết quả tốt
- + Sáng kiến / Cải thiện xã hội
- + Niềm tin / Hy vọng / Tầm nhìn

Xây dựng Guidline

— Một số ví dụ nhãn Positive:

- + “TPBank đặt mục tiêu lợi nhuận 9.000 tỷ đồng, chia cổ tức 10% bằng tiền mặt.”
- + “VitaDairy - Top 1 tăng trưởng nhanh nhất ngành sữa Việt Nam 2025.”
- + “Việt Nam đánh bại Thái Lan để vào chung kết.”
- + “Ra mắt giải pháp công nghệ hỗ trợ kiến tạo mô hình báo chí bền vững.”
- + “GSETS 2025: Lộ trình phát triển bền vững của Việt Nam trở thành chủ đề ‘nóng’.”

Xây dựng Guidline

- **Định nghĩa nhãn Neutral:** Bài báo chỉ cung cấp thông tin, tường thuật hoặc mô tả khách quan, không thể hiện thái độ khen/chê. Giọng văn trung lập, mang tính thông báo hoặc hành chính, không chứa yếu tố cảm xúc.

Xây dựng Guidline

— Một số nhóm cụ thể nhãn Neutral:

- + Nhóm Tin đa chiều: tích cực + tiêu cực cân bằng (50–50)
- + Nhóm Phân tích / Giải thích / Hỏi – đáp
- + Recap phim – kể lại tình tiết 1 tập phim
- + Tin Showbiz nói chung
- + Nhóm Thể thao chưa có kết quả
- + Tin hành chính / tổ chức / công bố / họp
- + Tường thuật sự kiện hoặc chính trị
- + Mô tả hiện tượng / xu hướng thị trường

Xây dựng Guidline

— Một số ví dụ nhãn Neutral:

- + “Vụ cô gái bị đánh hội đồng – chuyên gia chỉ cách giúp nạn nhân vượt qua.”
- + “Tập 12: Nhân vật chính gặp lại mẹ sau nhiều năm xa cách.”
- + “Hàng Du Mục bật khóc, đại diện công ty xin lỗi vì sai sót – neutral.”
- + “Giá máy giặt giảm một nửa, điều hòa xuống dưới 4 triệu đồng
Thị trường điện máy giảm giá mạnh để xả hàng tồn.”
- + “GSETS 2025: Lộ trình phát triển bền vững của Việt Nam trở thành chủ đề ‘nóng’.”

Xây dựng Guideline

- **Định nghĩa nhãn Negative:** Bài báo mô tả sự kiện, vấn đề, hoặc tình huống có hậu quả xấu, cảm xúc buồn, thiệt hại, xung đột, vi phạm, hoặc cảnh báo rủi ro. Giọng văn mang sắc thái nghiêm trọng, mất mát, bức xúc, cảnh giác, hoặc chỉ trích.

Xây dựng Guidline

- Một số nhóm cụ thể nhãn Negative:
 - + Tai nạn / Thiên tai / Mất mát
 - + Tội phạm / Vi phạm pháp luật
 - + Nhóm Kinh tế – Tài chính bất ổn
 - + Tranh cãi / Chỉ trích / Xung đột chính trị – xã hội
 - + Khó khăn cá nhân / Xã hội / Nghèo đói
 - + Nhóm Thể thao với kết quả xấu
 - + Nhóm Sức khỏe – Bệnh tật – Nguy cơ

Xây dựng Guildline

— Một số ví dụ nhãn Negative:

- + “2 người tử vong khi đang 'đấu lèo' trên cột điện.”
- + “Công an Vĩnh Long nêu khuyến cáo liên quan vụ nữ sinh tử vong.”
- + “Rao bán khoản nợ của doanh nghiệp gas lạnh đầu tiên của Việt Nam.”
- + “Danh hài Thanh Tùng 'Gala cười' tuổi 70 ở nhà thuê, nợ 20 triệu đồng không trả nổi.”
- + “Việt Nam thua Malaysia trong trận cầu quyết định.”

Xây dựng Guidline

— Phân biệt giữa các nhãn *Positive* ↔ *Neutral*:

- + Các bài viết dạng “tường thuật về sự kiện tốt” rất dễ bị gán nhầm giữa *Positive* và *Neutral*.
- + Nguyên nhân: tin có yếu tố tốt, nhưng giọng điệu trung lập hoặc chỉ mô tả sự kiện mà không khen/chúc mừng.

Xây dựng Guidline

— Phân biệt giữa các nhãn *Positive* ↔ *Neutral*:

- + Có từ ngữ cảm xúc hoặc thành tựu rõ ràng  **Positive.**
- + Chỉ tường thuật hoạt động, không đánh giá, không biểu cảm  **Neutral.**
- + Tin giới thiệu công nghệ, dự án, sản phẩm mới chỉ mô tả chức năng hoặc thông số  **Neutral.**
- + Tin đưa tầm nhìn, cơ hội, nỗ lực phát triển, hoặc khẳng định năng lực quốc gia/doanh nghiệp  **Positive.**

Xây dựng Guideline

— Phân biệt giữa các nhãn *Neutral* ↔ *Negative*:

- + Hai loại này dễ nhầm vì nhiều tin mang tính cảnh báo hoặc tiêu cực nhẹ, nhưng ngôn ngữ vẫn trung lập, không biểu cảm.
- + Annotator thường nhầm bài trung lập có thông tin xấu thành Negative, hoặc tin cảnh báo nhẹ thành Neutral.

Xây dựng Guidline

— Phân biệt giữa các nhãn *Neutral* ↔ *Negative*:

- + Tin chỉ mang thông tin, không bày tỏ cảm xúc, không nhấn mạnh thiệt hại  **Neutral**.
- + Tin cảnh báo, rủi ro, mất mát, hậu quả rõ ràng  **Negative**.
- + Tin có số liệu xấu hoặc bất lợi nhưng chỉ mang tính báo cáo, thống kê, không bộc lộ cảm xúc  **Neutral**.
- + Tin có nguy cơ, cảnh báo, hậu quả, hoặc yếu tố vi phạm pháp luật dù viết trung lập  **Negative**.

Xây dựng Guideline

— Phân biệt giữa các nhãn *Positive* ↔ *Negative*:

- + Một số bài báo có nhiều tầng cảm xúc — ví dụ “vượt khó thành công”, hoặc “tai nạn nhưng có hành động dũng cảm”.
- + Annotator phải xác định trọng tâm cảm xúc: bài nhấn mạnh mặt tích cực hay mặt tiêu cực.

Xây dựng Guidline

— Phân biệt giữa các nhãn *Positive* ↔ *Negative* :

- + Bắt đầu tiêu cực nhưng kết thúc tích cực (vượt khó, cứu người, đạt thành tựu) ✓ **Positive.**
- + Có cả hai yếu tố nhưng tiêu cực chiếm trọng tâm ✓ **Negative.**
- + Có yếu tố cảm động nhưng kết thúc buồn ✓ **Negative.**
- + Chỉ liệt kê “thói quen độc hại”, vấn đề xấu, không nêu hướng khắc phục ✓ **Negative.**
- + Nêu “thói quen độc hại” nhưng có giải pháp hoặc định hướng thay đổi tích cực ✓ **Positive.**

Xây dựng Guidline

— Các trường hợp mô hồ

- + Tin đa chủ đề (vừa tốt, vừa xấu).
- + Bài viết nhiều phát biểu khác nhau (người khen, người chê).
- + Thông tin chính trị, pháp lý.
- + Các tin liên quan tới quân sự.
- + Clickbait / tiêu đề gây hiểu lầm.
- + Ngôn ngữ mập mờ, không rõ thái độ.

QUY TRÌNH GÁN NHÃN & KIỂM SOÁT CHẤT LƯỢNG

Quy trình gán nhãn & Kiểm soát chất lượng

- Giai đoạn tiền huấn luyện annotators (tạo guideline).
- Giai đoạn huấn luyện annotators.
- Giai đoạn gán nhãn.

Quy trình gán nhãn & Kiểm soát chất lượng

Semantic Analysis Annotation Tool

5/2644 Reviews

Choose TXT File

Import

← Previous

Next →

Review #N/A

Người mẹ trần trở trước giờ ghi 'đơn xanh' nguyện vọng thi lớp 10 cho con — Trước sức nóng của kỳ thi vào lớp 10 Hà Nội, chị Nguyễn Thị Hoa (Hà Nội) nhiều ngày qua đau đầu trần trở, "đặt bút lên lại bỏ xuống" trước những quyết định đăng ký nguyện vọng chọn trường cho con.

Sentiment

Positive

Negative


Neutral

Save Label Annotations


Labeled Dataset

Download Dataset (JSON)


Quy trình gán nhãn & Kiểm soát chất lượng



Quy trình gán nhãn & Kiểm soát chất lượng



Quy trình gán nhãn & Kiểm soát chất lượng



Quy trình gán nhãn & Kiểm soát chất lượng

- Quá trình huấn luyện annotators được thực hiện trong tổng cộng 7 vòng, với mỗi vòng thực hiện gán độc lập giữa 3 annotators trong 200 mẫu. (có lí do rõ ràng khi quyết định số mẫu được gán mỗi vòng).
- Kết thúc quá trình huấn luyện khi độ đồng thuận (IAA) giữa 3 annotators > 0.8 (có lí do rõ ràng khi quyết định con số IAA).

Quy trình gán nhãn & Kiểm soát chất lượng

- Quá trình huấn luyện annotators được thực hiện trong tổng cộng 7 vòng, với mỗi vòng thực hiện gán độc lập giữa 3 annotators trong 200 mẫu. (có lí do rõ ràng khi quyết định số mẫu được gán mỗi vòng).
- Kết thúc quá trình huấn luyện khi độ đồng thuận (IAA) giữa 3 annotators > 0.8 (có lí do rõ ràng khi quyết định con số IAA).

Quy trình gán nhãn & Kiểm soát chất lượng

- Đảm bảo mỗi round có đủ “mẫu khó” để huấn luyện thật sự (không bị may rủi).
- Cho phép “đào tạo chống mindset drift” bằng cơ chế tái kiểm (retest).

Quy trình gán nhãn & Kiểm soát chất lượng

- Quá trình huấn luyện annotators được thực hiện trong tổng cộng 7 vòng, với mỗi vòng thực hiện gán độc lập giữa 3 annotators trong 200 mẫu. (có lí do rõ ràng khi quyết định số mẫu được gán mỗi vòng).
- Kết thúc quá trình huấn luyện khi độ đồng thuận (IAA) giữa 3 annotators > 0.8 (có lí do rõ ràng khi quyết định con số IAA).

Quy trình gán nhãn & Kiểm soát chất lượng

- Có “bất đồng không thể triệt tiêu” (irreducible ambiguity) trong tin báo chí.
 - + Ví dụ: “Nga tố NATO huy động số lượng lớn binh sĩ áp sát biên giới — Bộ trưởng Quốc phòng Nga Andrey Belousov cho biết, Tổ chức Hiệp ước Bắc Đại Tây Dương (NATO) đang duy trì sự hiện diện quân sự quy mô lớn gần biên giới Nga, đồng thời tăng cường các hoạt động huấn luyện và trinh sát.”
- $\text{Kappa} > 0.8$ là “đủ cao để tin được”, nhưng không đòi hỏi sự đồng thuận phi thực tế.

Quy trình gán nhãn & Kiểm soát chất lượng

Round	IAA
1	0.6353
2	0.6576
3	0.6671
4	0.7035
5	0.7265
6	0.7517
7 → Final round	0.8055

Quy trình gán nhãn & Kiểm soát chất lượng

Round	IAA	
1	0.6353	} Giai đoạn chuyển biến nhẹ.
2	0.6576	
3	0.6671	
4	0.7035	} Giai đoạn chuyển biến mạnh.
5	0.7265	
6	0.7517	
7 → Final round	0.8055	


Quy trình gán nhãn & Kiểm soát chất lượng

- Round 1: Chưa xác định rõ được vấn đề tại sao IAA thấp.
- Round 2 và 3: Các tin báo liên quan đến showbiz, câu nói của người nổi tiếng, các tư liệu lịch sử, tình tiết 1 tập film, và tin tức về bất động sản.

Quy trình gán nhãn & Kiểm soát chất lượng

- Round 4: Các tin báo liên quan đến quân sự: Khí tài quân sự phát triển, “sự xung đột” giữa các bên, thông tin chính trị trung lập, ...
- Round 6, 7: Guideline không thay đổi → IAA đạt mức mong muốn.

Quy trình gán nhãn & Kiểm soát chất lượng




TỔNG QUAN VỀ BỘ NGŨ LIỆU

Thống kê & Phân bố dữ liệu

- Tổng kích thước: 2,444 mẫu
- Phân chia tập dữ liệu (Data Split theo tỉ lệ 7:1:2):
 - + Training Set: 1,710 mẫu (~70%)
 - + Development (Dev) Set: 244 mẫu (~10%)
 - + Test Set: 490 mẫu (~20%)

Thống kê & Phân bố dữ liệu



THỰC NGHIỆM & ĐÁNH GIÁ

Data Preprocessing

- Chuyển văn bản về chữ thường
- Loại bỏ URLs, Hashtags, Mentions
- Loại bỏ số và dấu câu
- Word segmentation bằng pyvi
- Loại bỏ stopwords (từ điển stopwords của Việt Nam được lấy từ [vietnamese-stopword](#)) và xóa khoảng trắng thừa

Feature Extraction

- Nhóm mô hình Machine Learning:
 - + TF-IDF
 - + ngram
 - + max_features: None
- Nhóm mô hình Deep Learning: pre-trained Embedding + padding
 - + GRU: EMBEDDING_DIM = 200
 - + TextCNN: EMBEDDING_DIM = 300
- Nhóm mô hình Transformer: pre-trained AutoTokenizer

Model Implementations

- Logistic Regression
 - + $C = 10$
 - + Solver = lbfgs
- Linear SVM
 - + $C = 0.1$
 - + Class_weight = balanced
- Naive Bayes
 - + ComplementNB
 - + Alpha = 0.3

Model Implementations

— Decision Tree

- + criterion: gini
- + max_depth: 50
- + min_samples_split: 7
- + ngram_range: (1, 4)

— KNN

- + Metric = cosine
- + Neighbors = 9
- + Weights = distance

Model Implementations

- XGBoost
 - + Max Depth = 3
 - + Min Child Weight = 1
- Random Forest
 - + n_estimators = 300
 - + Min Samples Split = 5

Model Implementations

— GRU

- + batch_size = 32
- + epochs: 10 + early stopping
- + gru_units = 128
- + dropout_rate = 0.4
- + Optimizer: adam (learning_rate = 0.001)

Model Implementations

- TextCNN
 - + Batch_size = 64
 - + Epochs = 30
 - + dropout_rate = 0.5
 - + model__filters = 64
 - + Optimizer = adam

Model Implementations

— BERT

+ learning_rate = $3e-5$

+ batch_size = 16

+ Epochs = 10

+ weight_decay = 0.01

+ warmup_ratio = 0.1

Model Implementations

— PhoBERT

+ "learning_rate", 1e-5, 5e-5

+ "num_train_epochs", 3, 5

+ "per_device_train_batch_size", [16, 32]


+ "weight_decay", 0.0, 0.3

— Random seed = 42 cho tất cả phương pháp

Thực nghiệm & Đánh giá

	Model	Pre-trained model	Accuracy (%)	F1-macro (%)
Machine Learning models	Logistic Regression		70.41	70.57
	SVM		70.61	70.67
	Naive Bayes		71.43	71.12
	Descision Tree		54.69	53.83
	KNN		66.33	65.93
	XGBoost		63.27	62.82
	Random Forest		<u>71.84</u>	71.73
Deep Learning models	Text CNN		70.71	70.29
	GRU		<u>71.84</u>	72.03
Transformer models	BERT	bert-base-multilingual-cased	75.92	<u>75.86</u>
	PhoBERT	phobert-base-v2	75.92	76.11

Thực nghiệm & Đánh giá



Thực nghiệm & Đánh giá

#	Nội dung	True label	Pred label	Lí do
1	loài côn_trùng bé hạt gạo độc_tính gấp nọc rắn hổ kiến khoang chứa độc_tổ pederin độc_tính gấp nọc_rắn hổ tác_động da axit da tiếp_xúc tổn_thương bỏng_rát	Neutral	Negative	Mô hình bị "đánh lừa" bởi mật độ từ vựng tiêu cực dày đặc (độc tính, nọc rắn, tổn thương, bỏng rát) dù bài viết mang tính khách quan
2	indonesia sa_thải patrick kluivert thất_bại dự_án xây indonesia sa_thải patrick kluivert hụt vé world_cup kết_quả phản_ánh thất_bại dự_án xây	Negative	Neutral	Đây là tin về sự thất bại trong thể thao. Tuy nhiên giọng điều trung lập khiến mô hình nhầm lẫn là tin trung lập.
3	startup robot hình trung quốc bắt kịp elon musk startup agibot trung quốc mục_tieu sản_xuất robot hình cạnh_tranh optimus elon musk	Positive	Negative	Bài viết nói về sự tiến bộ. Tuy nhiên, từ khóa "cạnh tranh" được mô hình học là mang nghĩa xung đột hoặc tiêu cực trong các ngữ cảnh khác.

Thực nghiệm & Đánh giá

#	Nội dung	Nội dung gốc	True label	Pred label	Lí do
1	vợ mua thuốc hạ_mỡ máu uống khuyên chồng n t l long biên hà nội tình_cờ đọc thông_tin mạng rối_loạn mỡ máu mua thuốc hạ_mỡ máu uống khuyên chồng xét_nghiệm	"Người vợ tự mua thuốc hạ mỡ máu về uống và khuyên chồng dùng chung — ... tình cờ đọc được thông tin trên mạng về rối loạn mỡ máu, sau đó mua thuốc hạ mỡ máu về uống và khuyên chồng dùng chung mà không xét nghiệm."	Negative	Neutral	Mô hình hiểu nhầm hành động "nguy hại sức khỏe" thành hành động "khuyên đi khám bệnh"
2	ca_sĩ hồ ngọc hà hoàng_tử ballad thế_hệ minh khôi giọng ca_hát thu âm hồ ngọc hà hoàng_tử ballad thế_hệ	Ca sĩ khiến Hồ Ngọc Hà phải thốt lên 'Hoàng tử ballad thế hệ mới' là ai? — Minh Khôi - giọng ca hát trực tiếp mà như bản thu âm, khiến Hồ Ngọc Hà phải thốt lên đây là Hoàng tử ballad thế hệ mới.	Positive	Neutral	Câu văn bị biến đổi từ một lời khen thành một câu liệt kê hoạt động

Thực nghiệm & Đánh giá

- Hiệu quả vượt trội của Transformer (BERT/PhoBERT) chứng minh tính hiệu quả của kỹ thuật Transfer Learning đối với các bài toán có dữ liệu huấn luyện nhỏ.
- Sự ổn định của Machine Learning truyền thống.
- Các mô hình Deep Learning thuần túy (CNN/GRU) chưa tạo được đột phá do thiếu dữ liệu lớn để tự học các đặc trưng sâu.
- Decision Tree kém hiệu quả do dễ bị quá khớp (overfitting) và không nắm bắt tốt ngữ nghĩa trong không gian vector thưa.

KẾT LUẬN: ƯU ĐIỂM & HẠN CHẾ

Kết luận: Ưu điểm & Hạn chế

- Quy trình xây dựng dữ liệu chặt chẽ và tin cậy
- Chất lượng dữ liệu tốt và cân bằng
- Chiến lược trích xuất thông tin hiệu quả
- Thực nghiệm đa dạng
- Hiệu quả vượt trội của Transfer Learning: BERT, PhoBERT

Kết luận: Ưu điểm & Hạn chế

- Kích thước dữ liệu còn hạn chế đối với Deep Learning
- Thách thức về ngữ cảnh (Contextual Challenges)
- Độ phức tạp của ngôn ngữ báo chí

TÀI LIỆU THAM KHẢO

Tài liệu tham khảo

[1] S. T. Luu et al., "A large-scale dataset for hate speech detection on Vietnamese social media texts," arXiv preprint arXiv:2103.11528, 2021.

Công trình thực hiện

— Công trình của nhóm được public tại: [Github](#).

Cảm ơn thầy và các bạn đã lắng nghe
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN TP.HCM